



黎忠南 | 电话 13357308241

微信: CXKSBLi

求职意向: AI 应用开发 (后端) | 期望薪资: 面议 | 期望城市: 广州、深圳

教育背景: 广西科技大学 · 本科 · 土木工程 (土木工程建设与管理) | 2021-2025 | 曾任校组织运营部副部长

个人简介

面向 AI 应用开发方向, 独立完成一个已公网上线的 Multi-Agent 网关, 涵盖知识问答与支付体系。熟练使用 Claude Code / DeepSeek 等 AI 编程工具进行开发, 熟悉 LLM、RAG、Agent、提示词工程与大模型应用工程化落地。

项目经历

AI Agent 网关 | 架构设计 / 核心开发 | 2026.06 - 2026.8

源码仓库: github.com/Li-zner/Li-zner-repository 公网演示: <https://the-world-agent.cloud>

面向企业知识服务的 AI 网关, 含完整支付体系, 已上线公网稳定运行。独立完成从需求拆解、架构设计到开发、部署、运维的完整链路。

- 知识问答准确率低、答案不可溯源: 设计 RAG 双通道召回与重排, 实现向量数据库检索与 embedding 召回, 回答附法条出处并支持跨法域引导; 60 条专业用例评测综合 0.925, 回答忠诚度 99.92%。
- 多步任务容易中断或失控: 实现 Agent 循环与最大步数、重试、熔断、降级机制, 形成可控闭环, 规避死循环。
- 并发扣费存在超扣与丢流水: 使用 Redis 分布式锁与乐观锁, WAL 交易流水对账, 幂等防重复回调。
- 查询成本高、响应慢: 实现三级语义缓存, 命中查询成本降至约六成; 压测 800 并发平均响应 1.1s。
- 上线与运维: Docker Compose 编排 10+ 服务, Nginx 负载均衡并按 QPS 伸缩; Cloudflare Tunnel 公网暴露、密钥外置; Prometheus / Grafana / Tempo / Loki 监控告警。

技术栈

- 熟练: FastAPI / asyncio / PostgreSQL (pgvector、pg_trgm) / Redis / 提示词工程 / 向量检索与 embedding / RAG。
- 熟悉: Python / Docker Compose / Nginx / SSE 流式 / Prometheus / Grafana / JWT 认证 / 分布式锁与乐观锁 / Agent 编排 / 大模型 API 接入。
- 了解: LangChain / LangGraph 设计理念、Dify 平台、Kubernetes 基础概念。

大模型认知与实操

- **微调实操**: 在阿里云百炼平台使用自有数据集完成过模型微调训练, 理解 LoRA 等参数高效微调思路, 掌握过拟合、学习率、loss 收敛等训练指标的基础概念。
- **量化部署**: 本地部署量化模型: Ollama + GGUF 量化格式, 实测运行 Qwen 2.5B / 3.5B 与 DeepSeek 7B, 理解量化精度 (如 Q4_K_M) 对显存占用、推理速度与生成质量的取舍。
- **技术边界**: 能结合业务场景决策: 知识时效性与私有数据优先 RAG, 领域风格与特定能力优先微调, 复杂场景两者组合 (如知识库检索 + 领域术语风格输出)。
- **平台学习**: 阿里云大模型 ACP 相关经验: 系统学习了大模型原理、提示工程、微调、RAG、Agent 等核心知识体系。
- **工具箱**: Claude Code、OpenCode、Cursor、DeepSeek Harness、Visual Studio Code、Cherry Studio、WorkBuddy、影刀、Obsidian、OBS Studio 等